



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE INGENIERÍA
Año 2024 – 2.^{do} Cuatrimestre

REDES NEURONALES

Departamento de Electrónica
Trabajo Práctico I

2 de Octubre de 2024

Autor	Padrón	Correo electrónico
Gómez Villafañe, Marcos	— # 105 055 —	mgomezv@fi.uba.ar

Índice

1. Introducción	3
2. Entrenamiento y evaluación de la red de Hopfield	3
2.1. Memorización de las imágenes individuales	3
2.1.1. Versiones alteradas de imágenes	5
2.1.2. Estados espurios	6
2.2. Entrenamiento con imágenes de mismos tamaños	7
2.3. Entrenamiento con todas las imágenes	7
3. Capacidad de la red de Hopfield	10
4. Conclusión	15
5. Apéndice	16

1. Introducción

En este trabajo práctico se entrena una red de Hopfield '82 con imágenes binarias y se analizan las propiedades de la red neuronal y su capacidad de reproducir los patrones que memorizó.

2. Entrenamiento y evaluación de la red de Hopfield

En esta sección se entrena a la red de Hopfield primero con una imagen a la vez, luego una red para cada tamaño de imagen y finalmente una red con todas las imágenes al mismo tiempo. Se le presentan versiones alteradas de las imágenes usadas para entrenamiento y se evalúa la evolución de la red frente a dichas imágenes alteradas con ruido, elementos borrados o agregados.

2.1. Memorización de las imágenes individuales

La red de Hopfield consta de N neuronas todas interconectadas entre sí mediante pesos $w_{i,j}$ (peso de la neurona i a la j) tal que se obtiene una matriz de pesos $W \in \mathcal{R}^{N \times N}$ que es simétrica y con valores de 0 en la diagonal.

Primero, se entrena una red para cada una de las seis imágenes. Las imágenes son binarias y de distintas dimensiones. La red de Hopfield va a tener entonces N neuronas, representando cada neurona un píxel de la imagen.

El entrenamiento se realiza encontrando los valores de una matriz de pesos $W \in \mathcal{R}^{(\mathcal{W} \times \mathcal{H}) \times (\mathcal{W} \times \mathcal{H})}$. Esta matriz indica los pesos de las interconexiones entre neuronas i y j y se inicializa con ceros en la diagonal. La matriz W se adquiere con la actualización de la ecuación (2.1).

$$\Delta W_{i,j} = \begin{cases} \eta \times X_i \times X_j & \text{if } i \neq j \\ 0 & \text{if } i = j \end{cases} \quad (2.1)$$

donde X_i es el píxel i de la imagen y η es el valor de proporcionalidad e aprendizaje. Dado que se entrena con una única imagen $I = 1$, $W = \Delta W|_1$. Se utiliza un $\eta = 1$. Para el testeo del algoritmo, la red neuronal debe actualizar el valor de los píxeles de la imagen de entrada mediante el calculo de la salida de las neuronas, generando a la salida la imagen aprendida. Una red de Hoipfield se considera que memorizo la imagen si, al presentarle la imagen de entrenamiento, solo requiere una iteración de actualización (porque no debe cambiarla). La salida de la neurona i representa un pixel y se calcula mediante la multiplicación de los pesos a las otras neuronas (otros píxeles, $h = \sum_j W_{i,j} \cdot X_j$) y la función de activación f . Esto se observa en la figura ??.




Figura 2.1: Red de Hopfield y Neurona

Donde x_i son las salidas de las otras neuronas. La función de activación es en este caso la función signo, tal que

$$f(h) = \begin{cases} 1 & \text{if } h \geq 0 \\ 0 & \text{else} \end{cases} \quad (2.2)$$

Se entrena la red individualmente con cada imagen y se obtienen las siguientes matrices W , mostradas en la figura 2.2




Figura 2.2: Matrices W para las imágenes

Si bien parece en la imagen que la matriz W toma valores distintos de -1, 1 o 0, al hacer una verificación rápida todos los valores de W son -1, 1 o 0, la imagen simplemente hace un promedio de valores cercanos y por eso parece que toma valores de 0.25, por ejemplo. Importante mencionar también que los píxeles de las imágenes de entrenamiento toman valores 1 y -1 para el entrenamiento y testeo, esto tiene un impacto considerable sobre el entrenamiento.

Para el testeo, se recorre los píxeles de cada imagen y se los actualiza secuencialmente, esto es la actualización asincrónica. Adicionalmente, se permuta la actualización de cada pin, evitando estar recorriendo la imagen en un orden predeterminado. Se actualiza repetidamente los píxeles de la imagen hasta que no se cambia el valor de ningún píxel o hasta de se alcanza un número máximo de iteraciones. Al poner como entrada la misma imagen con la cual la red fue entrenada, se observa que converge a la primera iteración, lo cual indica que la red aprendió la imagen enseñada.



Figura 2.3: Entrenamiento con cada imagen, arriba la imagen memorizada y debajo la salida de la red

2.1.1. Versiones alteradas de imágenes

Se propone alterar las imágenes con ruido y con elementos borrados o agregados. El ruido se agrega con probabilidad entre 0 y 1 y se invierte el valor de un píxel con esa probabilidad. Por otro lado, los elementos borrados o agregados se introducen con un largo y ancho arbitrario y en una posición de la imagen arbitraria. Debajo se muestra las imágenes con ruido 0.2



Figura 2.4: Imágenes con ruido 0.2

Debajo las imágenes con rectángulos borrados en posiciones arbitrarias




Figura 2.5: Borrando partes de las imágenes

Se ve que la red logra reconstruir las imágenes en todos los casos. Sin embargo, puede pasar que la red provea imágenes erróneas, causadas por estados espurios en la minimización de la entropía,

2.1.2. Estados espurios

Con un ruido de 0.6, se ven estados espurios de todas las imágenes, donde la red neuronal aprende los patrones inversos y los muestra a la salida.



Figura 2.6: Patrones inversos

Es importante destacar que la red también puede converger a estos patrones inversos, ruido o combinaciones de patrones aprendidos. Por ejemplo, si la red neuronal aprende la paloma y el perro, puede generar una salida de un perro y una paloma en una misma imagen. Esto se ve en el entrenamiento con todas las imágenes mas adelante (ver figura 2.9). Los estados espurios generalmente se encuentran en pozos de energía menos profundos que los patrones almacenados. La energía tiene la forma

$$E = -\frac{1}{2} \sum_{i,j} w_{ij} v_i v_j \quad (2.3)$$

donde $v_{i,j}$ es el estado de la neurona i, j . Si las neuronas son elegidas al azar para actualizar sus valores de activación la red convergerá a estados que son mínimos locales de la función de

energía. Así, si un estado es un mínimo local en la función de energía será un estado estable de la red, es decir, un estado espurio.

2.2. Entrenamiento con imágenes de mismos tamaños

En esta sección se entrenan las imágenes originales con los mismos tamaños, obteniendo dos datasets de entrenamiento distintos,

- ◊ Dataset 1: Tamaño de 45×60 píxeles. Compuesto por la paloma, el torero y el quijote.
- ◊ Dataset 2: Tamaño de 50 píxeles. Compuesto por el panda, el perro y anonymous.

Para la red de Hopfield entrenada con el dataset 1, la red neuronal logra memorizar las imágenes e identificarlas inclusive bajo ruido de $p = 0,3$.




Figura 2.7: Entrenamiento y evaluación con ruido $p = 0,3$ para Dataset 1



Figura 2.8: Entrenamiento y evaluación con ruido $p = 0,3$ para Dataset 2

Se observa que entrenando dos redes de Hopfield, una para cada formato de imagen, las redes de Hopfield memorizan las tres imágenes y pueden reconstruir las imágenes con ruido.

2.3. Entrenamiento con todas las imágenes

Para poder entrenar a todas las imágenes con la misma red, dado que son de distintas dimensiones, se propone hacer un preprocesamiento de las imágenes tal que todas tengan la misma cantidad de píxeles. Los métodos propuestos son:

- ◇ Padding con blanco: Se agregan píxeles en 1 para rellenar el espacio en aquellas imágenes de menor resolución.
- ◇ Padding con ruido aleatorio: Se agregan píxeles de valor aleatorio -1 o 1 para rellenar el espacio en aquellas imágenes de menor resolución.

Con lo cual, ahora la cantidad de neuronas N es constante y equivale a $N = W \times H$, donde W es el ancho y H el alto. Por otro lado, la red de Hopfield necesita entradas en valores -1 y 1 , con lo cual se transforma el binario de esas imágenes a -1 y 1 multiplicando por 2 y restando 1.

Se procede ahora a entrenar una red de Hopfield con todas las imágenes disponibles. Para ello, se suman los $\Delta W|_i$ de cada imagen i tal que

$$W = \Delta W|_1 + \Delta W|_2 + \Delta W|_3 + \dots + \Delta W|_6 \quad (2.4)$$

Se comienza con 1 imagen (paloma), luego 2 imágenes (paloma y panda), luego 3 y así consecuentemente hasta obtener el entrenamiento con las 6 imágenes. La figura 2.9 muestra el entrenamiento al incorporar las imágenes una a la vez al entrenamiento de la red y evaluando en cada caso con todas las imágenes.




Figura 2.9: Entrenamiento con distintas cantidades de imágenes. A la izquierda la matriz W y a la derecha el testeo con las imágenes como entrada. De arriba a bajo: las primeras 3 imágenes, 4 imágenes, 5 imágenes y finalmente las 6 imágenes. Arriba la imagen original y debajo la reconstruida.

Se observa que la red neuronal no logra memorizar todos los patrones. Si bien esto puede ser interpretado como un problema de capacidad, en realidad esta no es la causa. La capacidad de la red neuronal de Hopfield puede estimarse para errores pequeños como ¹

$$C \approx 0,14N \quad (2.5)$$

Donde N es la cantidad de neuronas. En nuestro caso, la capacidad sería, para $N = 60 \times 50 = 3000$, $C \approx 420$, lo cual excede significativamente la cantidad de patrones enseñados. Por ende,

¹Fuente: <https://ml-jku.github.io/hopfield-layers/#introduction>

la capacidad no es la causa del error en el aprendizaje. La causa principal es la correlación entre las imágenes que se enseñan. Se necesita un modelo que pueda separar imágenes correlacionadas tal que la red neuronal pueda distinguirlas. Se demuestra que la correlación es la principal causa del no aprendizaje cambiando la forma en la cual se agrega un padding a la imagen. Ahora, el padding es aleatorios y se entrena nuevamente a la red neuronal. Debajo se muestra el resultado con esta nueva forma de ajustar el tamaño de las imágenes.




Figura 2.10: Entrenamiento reajustando con ruido el tamaño de imágenes. Arriba la imagen original y debajo la reconstruida.

Se observa que la red neuronal ahora puede aprender todas las imágenes excepto la paloma, demostrando que el problema esta en la correlación y la red neuronal es considerablemente sensible a como se ajusta el tamaño de las imágenes. Los errores para la paloma no son demasiados.

3. Capacidad de la red de Hopfield

Para hacer un análisis de la capacidad, se generan patrones aleatorios tal que la correlación tienda a ser nula mediante la siguiente formula

$$\vec{p} \quad ; \quad p_i \in \{1, -1\} \quad ; \quad \mathbb{P}(p_i = -1) = \mathbb{P}(p_i = 1) = 0,5 \quad (3.1)$$

Para una cantidad N de neuronas, se cuenta la cantidad de patrones que la red pudo aprender con un error menor a $p_{\text{error}} = E^{\text{max}}$ con

$$E = \frac{\# \text{Errores Totales}}{N \cdot M} \quad (3.2)$$

Con N el número de neuronas, M la cantidad de patrones aprendidos y los errores totales son la cantidad de bits no aprendidos al evaluar todos los patrones. La actualización de los bits se hace de forma sincrónica, es decir, se actualizan todos los valores al mismo tiempo. Realizando un barrido a través de la cantidad de neuronas y para un mismo p_{error} , se tiene el siguiente gráfico.




Figura 3.1: Patrones aprendidos y numero de neuronas

Se observa que la relación es lineal, con lo cual la relación entre la cantidad de neuronas y la cantidad de patrones aprendidos para un determinado umbral de error es constante. Para el caso ilustrado con $p_{\text{error}} = 0,1$, se tiene que $\frac{P}{N} = 0,656$. Si bien este no es el valor ideal de la tabla, el error se puede deber a que al principio (para pocas neuronas) la relación se distorsiona un poco.

Realizando el mismo análisis para distintos valores de p_{error} , dejando fijo la cantidad de neuronas en $N = 100$ y realizando un promediado con $S = 1000$ experimentos, se tiene la siguiente tabla de capacidad por neurona

p_{error}	$\frac{P_{\text{max}}}{N}$
0.001	0.122
0.0036	0.154
0.01	0.196
0.05	0.380
0.1	0.617

Tabla 1: Relación entre umbrales de error y la capacidad por neurona

Si bien los valores no son exactamente iguales a los descriptos en la tabla de la bibliografía, están en el orden descripto y coinciden con el orden. Se podría mejorar el resultado si se calcularan mas valores de neuronas y se promediaran mas puntos.

Para generar patrones de dimensión $p \in \mathcal{R}^D$ con grado de correlación σ , se usa una distribución gaussiana multivariable de media $\mu = \vec{0} \in \mathcal{R}^D$ y matriz de correlación $\Sigma \in \mathcal{R}^{D \times D}$. De




Figura 3.2: Correlaciones entre patrones

esta distribución se adquieren muestras con correlación σ tal que

$$\Sigma = \begin{bmatrix} 1 & \sigma & \dots & \sigma \\ \sigma & 1 & \dots & \sigma \\ \vdots & \vdots & & \vdots \\ \sigma & \sigma & \dots & 1 \end{bmatrix} \quad (3.3)$$

Para cada muestra correlacionada, se realiza la siguiente transformación sobre los componentes del patrón: $f(p_i), p_i \in p$ para obtener patrones con valores $p_i \in -1, 1$:

$$f(p) = \begin{cases} 1 & \text{if } p_i \geq 0 \\ -1 & \text{if } p_i < 0 \end{cases} \quad (3.4)$$

De esta forma, se generan los patrones correlacionados mediante la discretización de la gaussiana multivariable, manteniendo la correlación. Debajo se muestra un gráfico con la correlación de los patrones. Si bien no se pudo probar que la correlación se respeta del todo porque no se tiene una línea recta, esta generación de patrones correlacionados tiene un grado de sensibilidad a la correlación y es suficiente para probar su efecto sobre la capacidad. Esta no perfección en la correlación puede ser causado por la discretización de los valores gaussianos.

Para un error permitido de $p_e = 0,1$, y una cantidad de neuronas $N = 100$, se utilizan patrones con correlación $\sigma \in [0, 0,01, 0,02, \dots, 1,0]$ y se calcula la cantidad de patrones aprendidos P_{max} para dicha correlación. Adicionalmente, se realiza un promedio de 50 muestras para obtener valores confiables. El resultado de variar la correlación y medir la relación $\frac{P_{max}}{N}$ se muestra debajo




Figura 3.3: Tendencia de capacidad máxima y correlación para $p_e = 0,1$

Se observa una relación hiperbólica entre la capacidad y la correlación. Esto explica por que la red no pudo aprender las 6 imágenes, porque están correlacionadas y la correlación disminuye la capacidad. Notar que cuando correlación la correlación se acerca a 1, la capacidad aumenta. Esto es porque cuanto mas parecidos son los vectores, mas probable es que se trate del mismo vector, por lo tanto la capacidad aumenta cuando $\sigma \approx 1$ porque se trata del mismo vector en vez de vectores similares pero diferentes. Se realiza el mismo análisis con distintos umbrales de error p_e :




Figura 3.4: Capacidades con distintos umbrales de error

La tendencia de la curva de la misma pero la capacidad baja considerablemente dependiendo cual es el umbral de error permitido.

4. Conclusión

En este trabajo practico se pudo analizar en detalle la red de Hopfield, empezando desde su desarrollo en la primer etapa, el análisis de su respuesta frente a imágenes perturbadas y finalizando con un análisis de la capacidad de la red neuronal en función de la cantidad de neuronas y del efecto que tiene los patrones correlacionados sobre la capacidad. Los resultados obtenidos son acordes a los esperados y mencionados en la bibliografía y se cumplen las propiedades y limitaciones esperadas.

5. Apéndice

El código puede encontrarse en el siguiente link: https://colab.research.google.com/drive/1e0UwpykDQ20G1Pc_9mVpcRBoTG8F0Fmn?usp=sharing